

Aprendizaje Reforzado: Guía 1: Multi-armed Bandits

José Saint Germain

28 de septiembre de 2025

1. Ejercicio 1

Demostrar que, si conociéramos exactamente el valor de cada acción, es decir si *greedy* $A_t = \arg \max_a Q_t(a)$ en el sentido de que permite maximizar las recompensas totales.

1.1. Respuesta

En primer lugar debemos definir qué es la recompensa total. Una forma de hacerlo es sumando las recompensas en cada instante de tiempo y acumulándolas.

Entonces definimos a la recompensa total G_T como:

$$G_T = \sum_{t=1}^T R_t$$

¿Cuál es la recompensa total en promedio? Para saberlo calculamos el retorno esperado. Ese es el valor esperado G_T dada una secuencia de acciones T :

Retorno esperado: $E[G_T | A_1 = a_1, A_2 = a_2, \dots, A_T = a_T]$

Vamos a recurrir a las propiedades del valor esperado, dado que es una función lineal.

$$\text{linealidad del } \mathbb{E}[\cdot] \begin{cases} \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \\ \mathbb{E}[\alpha \cdot X] = \alpha \cdot \mathbb{E}[X] \end{cases}$$

Aplicando esas propiedades obtenemos que:

$$\text{Retorno esperado} = \sum_{t=1}^T E[R_t | A_t = a_t]$$

$$Retornoesperado = E[R_1|A_1 = a_1] + E[R_2|A_2 = a_2] + \dots + E[R_T|A_T = a_T]$$

La esperanza de R_1 dada la secuencia de acciones depende solo de la acción A_1 , porque la recompensa en el primer instante es independiente de la acción que se toma en instantes siguientes. Entonces esto hace que esta sumatoria equivalga a la sumatoria de las recompensas condicionadas solo a la acción tomada en el mismo instante de tiempo.

Entonces, para maximizar la suma debo maximizar cada término. Esos términos se maximizan cuando elijo la acción que da la máxima recompensa en promedio. Eso es exactamente igual a elegir $A_t = \arg \max_a Q_t(a)$, es decir la política Greedy.

2. Ejercicio 2

En una selección de acciones tipo ϵ - greedy con dos acciones posibles y $\epsilon=0.1$, ¿Cuál es la probabilidad de seleccionar la acción greedy?

2.1. Respuesta

La probabilidad de seleccionar la acción greedy es $1-\epsilon$, por lo tanto es de 0.9.

3. Ejercicio 3

Demostrar que el valor de una acción después de haber sido seleccionada $n - 1$ veces, definido como

$$Q_n = \frac{R_1 + R_2 + \dots + R_{n-1}}{n - 1}$$

, puede calcularse incrementalmente con la siguiente fórmula:

$$Q_n = Q_{n-1} + \frac{1}{n}[R_n - Q_{n-1}]$$

Describe la ventaja de esta fórmula desde un punto de vista computacional.

3.1. Respuesta

Siguiendo la expresión del enunciado, podemos expresar Q_{n+1} de la siguiente manera:

$$Q_{n+1} = \frac{R_1 + R_2 + \dots + R_{n-1} + R_n}{n}$$

A su vez, esta expresión podemos separarla en:

$$\frac{R_1 + R_2 + \dots + R_{n-1}}{n} + \frac{R_n}{n}$$

Adicionalmente, para tener $n - 1$ en el denominador del primer sumando, podemos multiplicar y dividir por $n - 1$:

$$\frac{R_1 + R_2 + \dots + R_{n-1}}{n-1} \cdot \frac{n-1}{n} + \frac{R_n}{n}$$

Reescribimos $\frac{R_1 + R_2 + \dots + R_{n-1}}{n-1}$ como Q_n :

$$= Q_n \cdot \frac{n-1}{n} + \frac{1}{n}R_n \quad (1)$$

$$= Q_n \cdot \frac{n}{n} - \frac{Q_n}{n} + \frac{1}{n}R_n \quad (2)$$

$$= Q_n - \frac{Q_n}{n} + \frac{1}{n}R_n \quad (3)$$

$$= Q_n + \frac{1}{n}[R_n - Q_n] \quad (4)$$

La ventaja de esta fórmula desde un punto de vista computacional es que no es necesario almacenar todas las recompensas obtenidas en cada paso, sino que solo es necesario almacenar el valor actual de Q_n y el número de veces que se ha seleccionado la acción n . Esto reduce el uso de memoria y hace que el cálculo sea más eficiente.

4. Ejercicio 4

Considere un problema k armedbandit con $k = 4$ acciones. Considere la aplicación de un algoritmo bandit usando selección de acciones ϵ -greedy, estimación incremental de los valores de cada acción y valores iniciales nulos $Q(a) = 0 \forall a$. Suponga la siguiente secuencia de acciones y recompensas: $A_1 = 1, R_1 = 1, A_2 = 2, R_2 = 1, A_3 = 2, R_3 = -2, A_4 = 2, R_4 = 2, A_5 = 3, R_5 = 0$. En algunos de estos pasos se ha tomado una decisión aleatoria.

- ¿En qué pasos definitivamente se tomaron decisiones aleatorias?
- ¿En qué pasos es posible que la decisión haya sido aleatoria?

4.1. Respuesta

En el primer paso de la secuencia, todos los valores iniciales son nulos, por lo tanto se eligió una acción aleatoria $A_1 = 1$ con recompensa $R_1 = 1$.

En el segundo paso, podemos calcular $Q(1)_2$ y $Q(2)_1$:

$$Q(1)_2 = Q(1)_1 + \frac{1}{1}[R_1 - Q(1)_1] = 0 + \frac{1}{1}[1 - 0] = 1$$

$$Q(2)_1 = 0 \text{ (valor inicial)}$$

Entonces sabemos que $Q(1)_2 > Q(2)_1$, por lo tanto la acción $A_2 = 2$ con recompensa $R_2 = 1$ fue tomada de forma aleatoria.

En el tercer paso, podemos calcular $Q(1)_2$ y $Q(2)_2$:

$$Q(1)_2 = 1 \text{ (calculado en el paso anterior)}$$

$$Q(2)_2 = Q(2)_1 + \frac{1}{1}[R_2 - Q(2)_1] = 0 + \frac{1}{1}[1 - 0] = 1$$

En este caso $Q(1)_2 = Q(2)_2$, por lo tanto la acción $A_3 = 2$ con recompensa $R_3 = -2$ pudo haber sido tomada de forma aleatoria o greedy.

En el cuarto paso, podemos calcular $Q(1)_2$ y $Q(2)_3$:

$$Q(1)_2 = 1 \text{ (calculado en el paso anterior)}$$

$$Q(2)_3 = Q(2)_2 + \frac{1}{2}[R_3 - Q(2)_2] = 1 + \frac{1}{2}[-2 - 1] = -0,5$$

En este caso $Q(1)_2 > Q(2)_3$, por lo tanto la acción $A_4 = 2$ con recompensa $R_4 = 2$ fue tomada de forma aleatoria.

En el quinto y último paso, podemos calcular $Q(1)_2$, $Q(2)_4$ y $Q(3)_1$:

$$Q(1)_2 = 1 \text{ (calculado en el paso anterior)}$$

$$Q(2)_4 = Q(2)_3 + \frac{1}{3}[R_4 - Q(2)_3] = -0,5 + \frac{1}{3}[2 - (-0,5)] = 0,33$$

$$Q(3)_1 = 0 \text{ (valor inicial)}$$

En este caso $Q(1)_2 > Q(2)_4 > Q(3)_1$, por lo tanto la acción $A_5 = 3$ con recompensa $R_5 = 0$ fue tomada de forma aleatoria.

5. Ejercicio 5

[Programación] Aplique el algoritmo bandit $\epsilon - greedy$ con $\epsilon = 0(greedy)$, $\epsilon = 0,01$ y $\epsilon = 0,1$ a un problema κ - armed bandit con $\kappa = 10$ acciones. Considere recompensas con medias aleatorias y desvío estándar constante σ . Analice experimentalmente el efecto de del desvío estándar σ evaluando tres casos: $\sigma = 0$ (determinístico), $\sigma = 1$ y $\sigma = 10$. ¿Qué conclusiones puede sacar?

5.1. Respuesta

En la imagen 1 se muestran los resultados del algoritmo ϵ -greedy.




Figura 1: Resultados del algoritmo ϵ -greedy con $\sigma = 0, 1, 10$

- Con $\sigma = 0$, el algoritmo con epsilon igual a cero va quedarse siempre en la primera acción que elija, por lo que no podrá explorar otras acciones. Por otra parte, con epsilon igual a 0.01 y 0.1 el algoritmo podrá explorar otras acciones y encontrar la mejor política, siendo el caso con epsilon igual a 0.1 el que más rápido converga a la mejor política.
- Con $\sigma = 1$ en $\epsilon = 0$ al principio consigue una mejora en su recompensa promedio, pero rápidamente vuelve a estancarse, mientras que con el resto de epsilon el comportamiento es similar al gráfico anterior con $\sigma = 0$, pero con una varianza mayor.
- Con $\sigma = 10$, la dispersión en las recompensas es tan grande que es irrelevante la elección del valor de epsilon.

Como conclusión, podemos inferir que el valor de la varianza influye en la capacidad del algoritmo para decidir el mejor curso de acción, puesto que la dispersión es tan alta entre máquinas, que las distribuciones de las recompensas de las máquinas se solapan ampliamente, haciendo casi indistinguible la ventaja entre elegir una u otra.

6. Ejercicio 6

Dada la fórmula adaptativa del valor $Q(n+1) = Q_n + a[R_n - Q_n]$ con $a \in (0, 1)$, demostrar que

- $Q_{n+1} = (1-a)^n Q_1 + \sum_{i=1}^n a(1-a)^{n-i} R_i$
- $(1-a)^n + \sum_{i=1}^n a(1-a)^{n-i} = 1$

es decir Q_{n+1} es un promedio pesado de $Q_n, R_1, R_2, \dots, R_n$.

6.1. Respuesta

6.1.1. Demostración 1

Demostraremos que $Q_{n+1} = (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha(1 - \alpha)^{n-i} R_i$

$$Q_{n+1} = Q_n + \alpha[R_n - Q_n] \quad (1)$$

$$Q_{n+1} = Q_n + \alpha R_n - \alpha Q_n \quad (2)$$

$$Q_{n+1} = \alpha R_n + (1 - \alpha)Q_n \quad (3)$$

$$Q_{n+1} = \alpha R_n + (1 - \alpha)[\alpha R_{n-1} + (1 - \alpha)Q_{n-1}] \quad (4)$$

$$Q_{n+1} = \alpha R_n + (1 - \alpha)\alpha R_{n-1} + (1 - \alpha)^2 Q_{n-1} \quad (5)$$

$$Q_{n+1} = \alpha R_n + (1 - \alpha)\alpha R_{n-1} + (1 - \alpha)^2 [\alpha R_{n-2} + (1 - \alpha)Q_{n-2}] \quad (6)$$

$$Q_{n+1} = \alpha R_n + (1 - \alpha)\alpha R_{n-1} + (1 - \alpha)^2 \alpha R_{n-2} + \dots + (1 - \alpha)^{n-1} \alpha R_1 + (1 - \alpha)^n Q_1 \quad (7)$$

$$Q_{n+1} = (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha(1 - \alpha)^{n-i} R_i \quad (8)$$

6.1.2. Demostración 2

Demostraremos que $(1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha(1 - \alpha)^{n-i} = 1$

Sabemos que $\sum_{i=1}^n \alpha(1 - \alpha)^{n-i}$ se puede escribir de la siguiente manera: $\alpha[(1 - \alpha)^{n-1} + (1 - \alpha)^{n-2} + \dots + 1]$.

Como $(1 - \alpha) < 1$, podemos usar la fórmula de la serie geométrica:

$$\alpha \frac{1 - (1 - \alpha)^n}{1 - (1 - \alpha)} = \alpha \frac{1 - (1 - \alpha)^n}{\alpha} = 1 - (1 - \alpha)^n$$

Remplazándolo en la ecuación inicial, obtenemos:

$$(1 - \alpha)^n + 1 - (1 - \alpha)^n = 1$$

7. Ejercicio 7

Demostrar que la fórmula adaptativa para calcular el valor $Q_{n+1} = Q_n + \alpha[R_n - Q_n]$ con step-size $\alpha \in (0, 1]$ constante no verifica la hipótesis de convergencia y por lo tanto no está garantizada su convergencia.

7.1. Respuesta

Analicemos cada condición por separado cuando $\alpha_n = \alpha$ es constante para todo n .

Condición 1: Verificación de $\sum_{n=1}^{\infty} \alpha_n = \infty$

$$\sum_{n=1}^{\infty} \alpha_n = \sum_{n=1}^{\infty} \alpha \quad (1)$$

$$= \alpha \sum_{n=1}^{\infty} 1 \quad (2)$$

$$= \alpha \cdot \infty = \infty \quad (3)$$

Dado que $\alpha > 0$, esta condición **SÍ se satisface**.

Condición 2: Verificación de $\sum_{n=1}^{\infty} \alpha_n^2 < \infty$

$$\sum_{n=1}^{\infty} \alpha_n^2 = \sum_{n=1}^{\infty} \alpha^2 \quad (4)$$

$$= \alpha^2 \sum_{n=1}^{\infty} 1 \quad (5)$$

$$= \alpha^2 \cdot \infty = \infty \quad (6)$$

Dado que $\alpha^2 > 0$ es constante, esta condición **NO se satisface**.

Puesto que no se verifica la condición 2, la fórmula adaptativa $Q_{n+1} = Q_n + \alpha[R_n - Q_n]$ con $\alpha \in (0, 1]$ constante **NO garantiza su convergencia**.

8. Ejercicio 8

En la figura 2.3 del libro de Sutton Barto (2018), se observa un *spike* en el paso número 11 cuando se utiliza la inicialización optimista. Dé una explicación de este fenómeno.

8.1. Respuesta

La inicialización optimista hace que todas las acciones tengan un valor inicial alto, lo que incentiva la exploración de todas las acciones. Una vez que la acción óptima es seleccionada, su valor se actualiza con la recompensa real obtenida, que es menor que el valor inicial optimista. Esto provoca que el valor de esa acción disminuya, creando el *spike* observado en la figura.

9. Ejercicio 9

Demuestre que la función SOFTMAX: $p(\alpha) = \frac{e^{H(\alpha)}}{\sum_{\alpha'=1}^K e^{H(\alpha')}}$ define una distribución de probabilidades discreta válida.

9.1. Respuesta

Para que una función defina una distribución de probabilidades discreta válida, debe cumplir dos condiciones:

1. Cada probabilidad debe ser mayor o igual a 0.
2. La suma de todas las probabilidades debe ser igual a 1.

9.1.1. Demostración 1: $0 \leq p_i(a) \leq 1$

Para cualquier acción a :

- $e^{H_i(a)} > 0$ para todo valor de $H_i(a)$, ya que la función exponencial es siempre positiva
- $\sum_{a'} e^{H_i(a')} > 0$, ya que es suma de términos estrictamente positivos

Por lo tanto:

$$p(a) = \frac{e^{H_i(a)}}{\sum_{a'} e^{H_i(a')}} \geq 0$$

A su vez, observemos que $e^{H_i(a)}$ es uno de los términos en la suma $\sum_{a'} e^{H_i(a')}$.

Por definición de suma:

$$e^{H_i(a)} \leq \sum_{a'} e^{H_i(a')}$$

Dividiendo ambos lados por $\sum_{a'} e^{H_i(a')} > 0$:

$$\frac{e^{H_i(a)}}{\sum_{a'} e^{H_i(a')}} \leq 1$$

Entonces, combinando ambas desigualdades:

$$0 \leq p_i(a) = \frac{e^{H_i(a)}}{\sum_{a'} e^{H_i(a')}} \leq 1$$

9.2. Demostración 2: $\sum_a p_i(a) = 1$

Calculemos la suma sobre todas las acciones:

$$\sum_a p_i(a) = \sum_a \frac{e^{H_i(a)}}{\sum_{a'} e^{H_i(a')}}.$$

Factorizando el denominador común:

$$= \frac{1}{\sum_{a'} e^{H_i(a')}} \cdot \sum_a e^{H_i(a)}$$

Como estamos sumando sobre todas las acciones posibles, ambas sumas recorren el mismo conjunto:

$$\sum_a e^{H_i(a)} = \sum_{a'} e^{H_i(a')}$$

Sustituyendo:

$$\sum_a p_i(a) = \frac{1}{\sum_{a'} e^{H_i(a')}} \cdot \sum_{a'} e^{H_i(a')} = 1$$

Por lo tanto, la suma de todas las probabilidades es igual a 1.

10. Ejercicio 10

Demostrar que las derivadas de la función SOFTMAX $p(x)$ respecto a sus parámetros $H(\alpha)$, $\alpha = 1, 2, \dots, K$ son iguales a:

$$\frac{\partial p(x)}{\partial H(\alpha)} = \begin{cases} p(x)(1 - p(x)) & \text{si } a = \alpha \\ -p(x)p(\alpha) & \text{si } a \neq \alpha \end{cases}$$

10.1. Respuesta

Para simplificar la notación, definamos:

- $S = \sum_{k=1}^K e^{H(k)}$ (denominador común)
- $p(x) = \frac{e^{H(x)}}{S}$

10.1.1. Caso 1: $\alpha = x$

Aplicamos la derivada del numerador.

$$\frac{\partial}{\partial H(x)}[e^{H(x)}] = e^{H(x)}$$

Aplicamos la derivada del denominador. Recordemos que $S = \sum_{k=1}^K e^{H(k)} = e^{H(1)} + e^{H(2)} + \dots + e^{H(K)}$

$$\frac{\partial S}{\partial H(x)} = \frac{\partial}{\partial H(x)} [e^{H(1)} + e^{H(2)} + \dots + e^{H(K)}]$$

Aplicando la derivada término por término:

- $\frac{\partial}{\partial H(x)}[e^{H(1)}] = 0$ si $1 \neq x$, pero $= e^{H(1)}$ si $1 = x$
- $\frac{\partial}{\partial H(x)}[e^{H(2)}] = 0$ si $2 \neq x$, pero $= e^{H(2)}$ si $2 = x$
- ...
- $\frac{\partial}{\partial H(x)}[e^{H(x)}] = e^{H(x)}$ (este término siempre contribuye)
- ...

Solo el término $e^{H(x)}$ tiene derivada no-cero, por lo tanto:

$$\frac{\partial S}{\partial H(x)} = e^{H(x)}$$

Aplicamos la regla del cociente:

$$\frac{\partial p(x)}{\partial H(x)} = \frac{e^{H(x)} \cdot S - e^{H(x)} \cdot e^{H(x)}}{S^2}$$

$$= \frac{e^{H(x)}(S - e^{H(x)})}{S^2}$$

$$= \frac{e^{H(x)}}{S} \cdot \frac{S - e^{H(x)}}{S}$$

$$= p(x) \cdot \left(1 - \frac{e^{H(x)}}{S}\right)$$

$$= p(x)(1 - p(x))$$

10.1.2. Caso 2: $\alpha \neq x$

Cuando $\alpha \neq x$, calculamos $\frac{\partial p(x)}{\partial H(\alpha)}$.

Aplicamos derivada del numerador:

$$\frac{\partial}{\partial H(\alpha)}[e^{H(x)}] = 0$$

(ya que $e^{H(x)}$ no depende de $H(\alpha)$ cuando $\alpha \neq x$)

Aplicamos derivada del denominador: Recordemos que $S = \sum_{k=1}^K e^{H(k)} = e^{H(1)} + e^{H(2)} + \dots + e^{H(K)}$

$$\frac{\partial S}{\partial H(\alpha)} = \frac{\partial}{\partial H(\alpha)} [e^{H(1)} + e^{H(2)} + \dots + e^{H(K)}]$$

Aplicando la derivada término por término:

- $\frac{\partial}{\partial H(\alpha)}[e^{H(1)}] = 0$ si $1 \neq \alpha$, pero $= e^{H(1)}$ si $1 = \alpha$
- $\frac{\partial}{\partial H(\alpha)}[e^{H(2)}] = 0$ si $2 \neq \alpha$, pero $= e^{H(2)}$ si $2 = \alpha$
- ...
- $\frac{\partial}{\partial H(\alpha)}[e^{H(\alpha)}] = e^{H(\alpha)}$ (este término siempre contribuye)
- ...

Solo el término $e^{H(\alpha)}$ tiene derivada no-cero, por lo tanto:

$$\frac{\partial S}{\partial H(\alpha)} = e^{H(\alpha)}$$

Aplicamos regla del cociente:

$$\frac{\partial p(x)}{\partial H(\alpha)} = \frac{0 \cdot S - e^{H(x)} \cdot e^{H(\alpha)}}{S^2}$$

$$= \frac{-e^{H(x)} \cdot e^{H(\alpha)}}{S^2}$$

$$= -\frac{e^{H(x)}}{S} \cdot \frac{e^{H(\alpha)}}{S}$$

$$= -p(x) \cdot p(\alpha)$$

11. Ejercicio 11

Demostrar que la regla de actualización por gradiente ascendente estocástico:

$$H_{t+1}(\alpha) = H_t(\alpha) + \alpha \frac{\partial E[R_t]}{\partial H_t(\alpha)'}$$

con $E[R_t] = \sum_{x=1}^K p_t(x)q_*(x)$ puede escribirse de la siguiente manera:

$$H_{t+1}(\alpha) = \begin{cases} H_t(\alpha) + \alpha(R_t - C)(1 - p_t(\alpha)) & \text{si } a = \alpha \\ H_t(\alpha) - \alpha(R_t - C)p_t(\alpha) & \text{si } a \neq \alpha \end{cases}$$

donde C es una constante cualquiera (usualmente se usa $C = \bar{R}_t$, el promedio de recompensas anteriores).

11.1. Respuesta

11.1.1. Planteo del problema

Sabemos que el esperado de la recompensa es:

$$E[R_t] = \sum_{x=1}^K p_t(x)q_*(x)$$

Calculamos $\frac{\partial E[R_t]}{\partial H_t(\alpha)}$:

$$\begin{aligned} \frac{\partial E[R_t]}{\partial H_t(\alpha)} &= \frac{\partial}{\partial H_t(\alpha)} \left[\sum_{x=1}^K p_t(x)q_*(x) \right] \\ &= \sum_{x=1}^K q_*(x) \frac{\partial p_t(x)}{\partial H_t(\alpha)} \end{aligned}$$

Además, de la demostración anterior, sabemos que:

$$\frac{\partial p_t(x)}{\partial H_t(\alpha)} = \begin{cases} p_t(x)(1 - p_t(x)) & \text{si } \alpha = x \\ -p_t(x)p_t(\alpha) & \text{si } \alpha \neq x \end{cases}$$

Sustituyendo:

$$\frac{\partial E[R_t]}{\partial H_t(\alpha)} = \sum_{x=1}^K q_*(x) \frac{\partial p_t(x)}{\partial H_t(\alpha)}$$

Separando los casos:

$$\begin{aligned}
&= q_*(\alpha) \cdot p_t(\alpha)(1 - p_t(\alpha)) + \sum_{x \neq \alpha} q_*(x) \cdot (-p_t(x)p_t(\alpha)) \\
&= q_*(\alpha)p_t(\alpha)(1 - p_t(\alpha)) - p_t(\alpha) \sum_{x \neq \alpha} q_*(x)p_t(x)
\end{aligned}$$

Podemos reescribir:

$$\sum_{x \neq \alpha} q_*(x)p_t(x) = \sum_{x=1}^K q_*(x)p_t(x) - q_*(\alpha)p_t(\alpha) = E[R_t] - q_*(\alpha)p_t(\alpha)$$

Sustituyendo:

$$\frac{\partial E[R_t]}{\partial H_t(\alpha)} = q_*(\alpha)p_t(\alpha)[1 - p_t(\alpha)] - p_t(\alpha)[E[R_t] - q_*(\alpha)p_t(\alpha)]$$

Distribuimos $q_*(\alpha)$ y $q_*(\alpha)p_t(\alpha)$:

$$= q_*(\alpha)p_t(\alpha) - q_*(\alpha)p_t^2(\alpha) - p_t(\alpha)E[R_t] + q_*(\alpha)p_t^2(\alpha)$$

Cancelamos términos semejantes:

$$= q_*(\alpha)p_t(\alpha) - p_t(\alpha)E[R_t]$$

Tomamos $p_t(\alpha)$ como factor común:

$$= p_t(\alpha)(q_*(\alpha) - E[R_t])$$

11.1.2. Construcción de estimadores no sesgados

En la práctica, **no conocemos** $q_*(\alpha)$ para todas las acciones. Solo observamos:

- La acción seleccionada A_t
- La recompensa obtenida R_t

Por tanto, necesitamos **construir un estimador no sesgado** del gradiente usando solo esta información limitada.

Del paso anterior obtuvimos:

$$\frac{\partial E[R_t]}{\partial H_t(\alpha)} = p_t(\alpha)(q_*(\alpha) - E[R_t])$$

Para construir estimadores no sesgados, necesitamos que $E[\text{estimador}] = \text{valor real}$.

Caso 1: $\alpha = A_t$ (acción seleccionada)

Cuando seleccionamos la acción α , observamos R_t que es una muestra de $q_*(\alpha)$, es decir: $E[R_t | A_t = \alpha] = q_*(\alpha)$

Para obtener un estimador no sesgado del gradiente, aplicamos la identidad fundamental de **policy gradients**:

$$E \left[\frac{R_t - C}{p_t(A_t)} \cdot \frac{\partial p_t(A_t)}{\partial H_t(\alpha)} \right] = \frac{\partial E[R_t]}{\partial H_t(\alpha)}$$

Cuando $A_t = \alpha$:

- $\frac{\partial p_t(\alpha)}{\partial H_t(\alpha)} = p_t(\alpha)(1 - p_t(\alpha))$
- Por tanto: $\frac{R_t - C}{p_t(\alpha)} \cdot p_t(\alpha)(1 - p_t(\alpha)) = (R_t - C)(1 - p_t(\alpha))$

Nuestro estimador es: $\hat{\nabla}_\alpha = (R_t - C)(1 - p_t(\alpha))$

Caso 2: $\alpha \neq A_t$ (acción no seleccionada)

Cuando no seleccionamos la acción α , no observamos $q_*(\alpha)$ directamente. Sin embargo, podemos construir un estimador no sesgado usando la restricción fundamental de las probabilidades.

Dado que $\sum_{x=1}^K p_t(x) = 1$, tenemos que: $\sum_{x=1}^K \frac{\partial p_t(x)}{\partial H_t(\alpha)} = 0$

Esto significa que los estimadores deben sumar cero. Como el estimador para la acción seleccionada es $(R_t - C)(1 - p_t(A_t))$, los estimadores para las acciones no seleccionadas deben compensar:

$$\hat{\nabla}_\alpha = -(R_t - C)p_t(\alpha)$$

11.1.3. Introducción del baseline

Como $E[R_t]$ es desconocido, lo reemplazamos por un baseline C :

- C puede ser cualquier constante (típicamente el promedio de recompensas pasadas)
- Esto no introduce sesgo porque $E[C] = C$ es constante
- El baseline reduce la varianza del estimador sin afectar el valor esperado

11.1.4. La Regla de Actualización Final

Aplicando $H_{t+1}(\alpha) = H_t(\alpha) + \alpha \cdot \widehat{\nabla}_\alpha$:

Si $\alpha = A_t$ (acción seleccionada):

$$H_{t+1}(\alpha) = H_t(\alpha) + \alpha(R_t - C)(1 - p_t(\alpha))$$

Si $\alpha \neq A_t$ (acción no seleccionada):

$$H_{t+1}(\alpha) = H_t(\alpha) - \alpha(R_t - C)p_t(\alpha)$$

Resultado final:

$$H_{t+1}(\alpha) = \begin{cases} H_t(\alpha) + \alpha(R_t - C)(1 - p_t(\alpha)) & \text{si } \alpha = A_t \\ H_t(\alpha) - \alpha(R_t - C)p_t(\alpha) & \text{si } \alpha \neq A_t \end{cases}$$