

Aprendizaje Reforzado: Guía 4: Métodos Monte Carlo

José Saint Germain

5 de octubre de 2025

1. Ejercicio 1

Considere un proceso de decisión de Markov (MDP) con dos estados: uno terminal y otro no-terminal. Existe sólo una acción que lleva del estado no-terminal al estado terminal con probabilidad $1-p$ y del estado no-terminal a sí mismo con probabilidad p . La recompensa es $+1$ en todas las transiciones y el factor de descuento es $\gamma = 1$. Suponga que observa un episodio con 10 iteraciones y un retorno de 10.

1. ¿Cuáles son las estimaciones Monte Carlo de primer-visita y de cada-visita del valor del estado no-terminal basadas en ese episodio?
2. Compare los valores de estado obtenidos con el teórico $p=0.9$. Saque conclusiones.

1.1. Resolución

1.1.1. Parte 1

En el método de primera visita, solo consideramos la primera vez que visitamos el estado no-terminal.

- **Primera visita al estado no-terminal:** tiempo $t = 0$
- **Retorno desde $t = 0$:** Como $\gamma = 1$, el retorno es la suma de todas las recompensas futuras:

$$G_0 = r_1 + r_2 + r_3 + \cdots + r_{10} = 1 + 1 + 1 + \cdots + 1 = 10$$

En el método de cada visita, consideramos todas las veces que visitamos el estado no-terminal.

- Visita en $t = 0$: $G_0 = 10$
- Visita en $t = 1$: $G_1 = 9$
- Visita en $t = 2$: $G_2 = 8$
- Visita en $t = 3$: $G_3 = 7$
- Visita en $t = 4$: $G_4 = 6$
- Visita en $t = 5$: $G_5 = 5$
- Visita en $t = 6$: $G_6 = 4$
- Visita en $t = 7$: $G_7 = 3$
- Visita en $t = 8$: $G_8 = 2$
- Visita en $t = 9$: $G_9 = 1$

Estimación de cada visita:

$$V_{\text{every}}(S_0) = \frac{1}{10} \sum_{i=0}^9 G_i = \frac{10 + 9 + 8 + 7 + 6 + 5 + 4 + 3 + 2 + 1}{10} = \frac{55}{10} = 5,5$$

1.1.2. Parte 2

Para calcular el valor teórico del estado no-terminal con $p = 0,9$, usamos la ecuación de Bellman:

$$V(S_0) = \mathbb{E}[R + \gamma V(S')]$$

donde:

- Con probabilidad $p = 0,9$: transición a terminal, $R = 1$, $V(S_T) = 0$
- Con probabilidad $1 - p = 0,1$: transición a sí mismo, $R = 1$, $V(S_0)$

La ecuación queda:

$$\begin{aligned} V(S_0) &= p \cdot (1 + \gamma \cdot 0) + (1 - p) \cdot (1 + \gamma \cdot V(S_0)) \\ &= p \cdot 1 + (1 - p) \cdot (1 + 1 \cdot V(S_0)) \\ &= p + (1 - p) + (1 - p)V(S_0) \end{aligned}$$

Resolviendo para $V(S_0)$:

$$V(S_0) = 1 + (1 - p)V(S_0)$$

$$V(S_0) - (1 - p)V(S_0) = 1$$

$$pV(S_0) = 1$$

$$V(S_0) = \frac{1}{p}$$

Para $p = 0,9$:

$$V_{\text{teórico}}(S_0) = \frac{1}{0,9} = \frac{10}{9} \approx 1,111$$

En conclusión, con una sola visita la estimación Monte Carlo es muy sesgada, mientras que con varias visitas se acerca más al valor teórico, pero sigue siendo una estimación alta. Esto se debe a que con $p = 0,9$, el agente tiende a permanecer mucho tiempo en el estado no-terminal y acumula muchas recompensas antes de transicionar al estado terminal.

2. Ejercicio 2

Demostrar que la política $\epsilon - Greedy$, definida de la siguiente manera

$$\pi(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{si } a = a^* \\ \frac{\epsilon}{|A(s)|} & \text{si } a \neq a^* \end{cases}$$

es una distribución de probabilidad válida, donde $|A(s)|$ es el número de acciones posibles para el estado s , $\epsilon < 1$ es un número positivo pequeño, y a^* es la acción óptima (decisión greedy) para el estado s . ¿Hay que pedir alguna condición sobre ϵ ?

2.1. Resolución

Para que $\pi(a|s)$ sea una distribución de probabilidad válida, debe cumplir dos condiciones:

1. Normalización: La suma de las probabilidades de todas las acciones posibles debe ser igual a 1, es decir, $\sum_{a \in A(s)} \pi(a|s) = 1$.
2. No negatividad: $\pi(a|s) \geq 0$ para todas las acciones a en el conjunto de acciones $A(s)$.

2.1.1. No negatividad

Para $A \neq a^*$ $\pi(a|s) = \frac{\epsilon}{|A(s)|} \geq 0$. Esto se puede demostrar que es mayor o igual a 0 si $\epsilon \geq 0$.

Si $A = a^*$ $\pi(a|s) = 1 - \epsilon + \frac{\epsilon}{|A(s)|} \geq 0$

Se puede reescribir como $1 - \epsilon(1 - \frac{1}{|A(s)|})$

$1 - \epsilon(1 - \frac{1}{|A(s)|}) \geq 0$, entonces la expresión va a ser mayor o igual a 0 si $1 \geq \epsilon(1 - \frac{1}{|A(s)|})$.

De aquí surge una condición necesaria para ϵ : $\epsilon \leq \frac{1}{|A(s)|-1}$.

2.1.2. Normalización

$$\sum_a \pi(a|s) = \pi(a^*|s) + \sum_{a \neq a^*} \pi(a|s)$$

Remplazando los valores de $\pi(a|s)$:

$$= 1 - \epsilon + \frac{\epsilon}{|A(s)|} + \sum_{a \neq a^*} \frac{\epsilon}{|A(s)|}$$

Remplazamos por el número de acciones menos 1 (la acción óptima):

$$\begin{aligned} &= 1 - \epsilon + \frac{\epsilon}{|A(s)|} + (|A(s)| - 1) \frac{\epsilon}{|A(s)|} \\ &= 1 - \epsilon + \frac{\epsilon}{|A(s)|} + \epsilon - \frac{\epsilon}{|A(s)|} \\ &= 1 - \epsilon + \epsilon = 1 \end{aligned}$$

Por lo tanto, se cumple la condición de normalización.

3. Ejercicio 3

Se dice que una política π es $\epsilon - soft$ si $\pi(a|s) \geq \frac{\epsilon}{|A(s)|} \forall a \neq a^* \forall s$. Demostrar que la política $\epsilon - Greedy \pi'(a|s) \geq \frac{\epsilon}{|A(s)|}$ (definida en el ejercicio 1) es igual o mejor que cualquier política $\epsilon - soft$, es decir, $v_{\pi'}(s) \geq v_{\pi}(s) \forall s$.

3.1. Resolución

Con la información recibida, tenemos que demostrar (por el teorema de la mejora de la política) que:

$$q_{\pi}(s, \pi'(s)) \geq v_{\pi}(s)$$

Sabemos que:

$$q_\pi(s, \pi'(s)) = E[G_t | S_t = s, A_t = \pi'(s)]$$

como $A_t = \pi'(s)$ es determinístico, lo podemos reescribir:

$$q_\pi(s, \pi'(s)) = E_\pi[G_t | S_t = s] = \sum_g gp(g|s)$$

hacemos la probabilidad marginal:

$$= \sum_g \sum_a p(g, a|s)$$

aplicamos el teorema de Bayes:

$$= \sum_g \sum_a p(g|s, a)p(a|s)$$

sabiendo que $p(a|s) = \pi'(a|s)$ y $\sum_g p(g|s, a) = q(s, a)$:

$$q_\pi(s, \pi'(s)) = \sum_a \pi'(a|s)q(s, a)$$

esta sumatoria se puede separar en la acción óptima y las demás:

$$= \pi'(a^*|s)q(s, a^*) + \sum_{a \neq a^*} \pi'(a|s)q(s, a)$$

reemplazamos los valores de $\pi'(a|s)$:

$$\begin{aligned} &= (1 - \epsilon + \frac{\epsilon}{|A(s)|})q_\pi(s, a^*) + \sum_{a \neq a^*} \frac{\epsilon}{|A(s)|} q_\pi(s, a) \\ &= (1 - \epsilon)q_\pi(s, a^*) + \frac{\epsilon}{|A(s)|} \sum_a q_\pi(s, a) \end{aligned}$$

distribuyendo $q_\pi(s, a^*)$:

$$q_\pi(s, a^*)(1 - \epsilon) + q_\pi(s, a^*)\frac{\epsilon}{|A(s)|} + \frac{\epsilon}{|A(s)|} \sum_{a \neq a^*} q_\pi(s, a)$$

junto las sumatorias $\forall a$:

$$= q_\pi(s, a^*)(1 - \epsilon) + \frac{\epsilon}{|A(s)|} \sum_a q_\pi(s, a)$$

reemplazo $q_\pi(s, a)$ por:

$$= q_\pi(s, a^*) = \sum_a c(a)q_\pi(s, a) \text{ si } \sum_a c(a) = 1$$

Asumimos que $q \sum_a c(a)q_\pi(s, a) \leq q_\pi(s, a^*)$

$$q_\pi(s, a^*) \geq \frac{\epsilon}{|A(s)|} \sum_{|A(s)|} q_\pi(s, a) + (1 - \epsilon) \sum_a c(a) q_\pi(s, a)$$

Elijo unos codificientes definidos como:

$$c(a) = \frac{\pi(a|s) - \frac{\epsilon}{|A(s)|}}{1 - \epsilon}$$

sabiendo que la sumatoria de todos los coeficientes es 1:

$$\sum_a c(a) = \sum_a \frac{\pi(a|s) - \frac{\epsilon}{|A(s)|}}{1 - \epsilon} = \frac{1 - \epsilon}{1 - \epsilon} = 1$$

remplazando c(a) en la desigualdad:

$$q_\pi(s, a^*) \geq \frac{\epsilon}{|A(s)|} \sum_{|A(s)|} q_\pi(s, a) + \sum_a \pi(a|s) q_\pi(s, a) - \frac{\epsilon}{|A(s)|} \sum_a q_\pi(s, a)$$

cancelo los términos semejantes:

$$q_\pi(s, a^*) \geq \sum_a \pi(a|s) q_\pi(s, a) \stackrel{\text{definición}}{=} v_\pi(s)$$

entonces,

$$q_\pi(s, \pi'(s)) \geq v_\pi(s)$$

que es equivalente (por teorema de la mejora de la política) a:

$$\nu_{\pi'}(s) \geq \nu_\pi(s)$$

4. Ejercicio 4

Dada una trayectoria de acciones y estados $A_t, S_{t+1}, A_{t+1}, \dots, S_T$ en un proceso de decisión markoviano (MDP) con política $\pi(a|s)$, demostrar que la probabilidad conjunta de esa trayectoria se puede escribir como:

$$P[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} \pi(A_k|S_k) p(S_{k+1}|S_k, A_k)$$

Nota: considere $P[S_t] = 1$.

4.1. Resolución

Por la regla de la cadena:

$$\begin{aligned} P[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] &= P[S_t] \cdot P[A_t|S_t] \\ &\quad \cdot P[S_{t+1}|S_t, A_t] \\ &\quad \cdot P[A_{t+1}|S_t, A_t, S_{t+1}] \\ &\quad \cdot P[S_{t+2}|S_t, A_t, S_{t+1}, A_{t+1}] \\ &\quad \dots \end{aligned}$$

En un MDP el siguiente estado depende solo del estado y acción actuales:

$$P[S_{k+1}|S_t, A_t, \dots, S_k, A_k] = P(S_{k+1}|S_k, A_k)$$

Y por política estocástica, la acción depende solo del estado actual:

$$P[A_k|S_t, A_t, \dots, S_k] = \pi(A_k|S_k)$$

Aplicando estas propiedades:

$$P[S_t, A_t, S_{t+1}, \dots, S_T] = P[S_t] \prod_{k=t}^{T-1} \pi(A_k|S_k) \cdot P(S_{k+1}|S_k, A_k)$$

Dado que $P[S_t] = 1$, obtenemos:

$$P[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} \pi(A_k|S_k) P(S_{k+1}|S_k, A_k)$$

5. Ejercicio 5

Usando el resultado del ejercicio 4, demostrar que el importance-sampling ratio correspondiente a la aplicación del método off-policy es:

$$\rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|S_k)}$$

5.1. Resolución

Sabiendo que:

$$P_\pi[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} \pi(A_k|S_k) P(S_{k+1}|S_k, A_k)$$

De manera análoga, la probabilidad de la misma trayectoria bajo la política de comportamiento b es:

$$P_b[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} b(A_k|S_k)P(S_{k+1}|S_k, A_k)$$

El *importance-sampling ratio* se define como el cociente entre la probabilidad de la trayectoria bajo la política objetivo y la probabilidad bajo la política de comportamiento:

$$\begin{aligned} \rho_{t:T-1} &= \frac{P_\pi[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T]}{P_b[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T]} \\ &= \frac{\prod_{k=t}^{T-1} \pi(A_k|S_k)P(S_{k+1}|S_k, A_k)}{\prod_{k=t}^{T-1} b(A_k|S_k)P(S_{k+1}|S_k, A_k)} \\ &= \frac{\prod_{k=t}^{T-1} \pi(A_k|S_k) \cdot \prod_{k=t}^{T-1} P(S_{k+1}|S_k, A_k)}{\prod_{k=t}^{T-1} b(A_k|S_k) \cdot \prod_{k=t}^{T-1} P(S_{k+1}|S_k, A_k)} \end{aligned}$$

simplificamos la fracción:

$$= \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|S_k)}$$

6. Ejercicio 6

Demostrar que la fórmula de la implementación incremental de un promedio ponderado, es decir, el promedio ponderado

$$V_n = \frac{\sum_{k=1}^{n-1} W_k G_k}{\sum_{k=1}^{n-1} W_k}$$

puede calcularse incrementalmente con la fórmula:

$$V_{n+1} = V_n + \frac{W_n}{C_n} [G_n - V_n]$$

con $C_{n+1} = C_n + W_{n+1}$.

6.1. Resolución

Sea $C_n = \sum_{k=1}^n W_k$ el acumulador de pesos hasta el paso n . Entonces:

$$V_n = \frac{\sum_{k=1}^n W_k G_k}{C_n}$$

Por definición:

$$V_{n+1} = \frac{\sum_{k=1}^{n+1} W_k G_k}{C_{n+1}} = \frac{\sum_{k=1}^{n+1} W_k G_k}{C_n + W_{n+1}}$$

Podemos escribir:

$$V_{n+1} = \frac{\sum_{k=1}^n W_k G_k + W_{n+1} G_{n+1}}{C_n + W_{n+1}}$$

Sabemos que $\sum_{k=1}^n W_k G_k = V_n \cdot C_n$, entonces:

$$V_{n+1} = \frac{V_n C_n + W_{n+1} G_{n+1}}{C_n + W_{n+1}}$$

Como $C_{n+1} = C_n + W_{n+1}$:

$$\begin{aligned} V_{n+1} &= \frac{V_n C_n + W_{n+1} G_{n+1}}{C_{n+1}} \\ &= \frac{V_n C_n}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \end{aligned}$$

Podemos reescribir el primer término:

$$\begin{aligned} V_{n+1} &= \frac{V_n C_n}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ &= \frac{V_n (C_{n+1} - W_{n+1})}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ &= \frac{V_n C_{n+1} - V_n W_{n+1}}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ &= V_n - \frac{V_n W_{n+1}}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ V_{n+1} &= V_n + \frac{W_{n+1} G_{n+1} - V_n W_{n+1}}{C_{n+1}} \\ &= V_n + \frac{W_{n+1}}{C_{n+1}} (G_{n+1} - V_n) \end{aligned}$$

Si reemplazamos $n + 1$ por n en la fórmula final (es decir, consideramos la actualización del paso $n - 1$ al paso n), obtenemos:

$$V_{n+1} = V_n + \frac{W_n}{C_n}[G_n - V_n]$$