

Aprendizaje Reforzado: Guía 4: Métodos Monte Carlo

José Saint Germain

1 de noviembre de 2025

1. Ejercicio 1

Considere un proceso de decisión de Markov (MDP) con dos estados: uno terminal y otro no-terminal. Existe sólo una acción que lleva del estado no-terminal al estado terminal con probabilidad $1-p$ y del estado no-terminal a sí mismo con probabilidad p . La recompensa es $+1$ en todas las transiciones y el factor de descuento es $\gamma = 1$. Suponga que observa un episodio con 10 iteraciones y un retorno de 10.

1. ¿Cuáles son las estimaciones Monte Carlo de primer-visita y de cada-visita del valor del estado no-terminal basadas en ese episodio?
2. Compare los valores de estado obtenidos con el teórico $p=0.9$. Saque conclusiones.

1.1. Resolución

1.1.1. Parte 1

En el método de primera visita, solo consideramos la primera vez que visitamos el estado no-terminal.

- **Primera visita al estado no-terminal:** tiempo $t = 0$
- **Retorno desde $t = 0$:** Como $\gamma = 1$, el retorno es la suma de todas las recompensas futuras:

$$G_0 = r_1 + r_2 + r_3 + \cdots + r_{10} = 1 + 1 + 1 + \cdots + 1 = 10$$

En el método de cada visita, consideramos todas las veces que visitamos el estado no-terminal.

- Visita en $t = 0$: $G_0 = 10$
- Visita en $t = 1$: $G_1 = 9$
- Visita en $t = 2$: $G_2 = 8$
- Visita en $t = 3$: $G_3 = 7$
- Visita en $t = 4$: $G_4 = 6$
- Visita en $t = 5$: $G_5 = 5$
- Visita en $t = 6$: $G_6 = 4$
- Visita en $t = 7$: $G_7 = 3$
- Visita en $t = 8$: $G_8 = 2$
- Visita en $t = 9$: $G_9 = 1$

Estimación de cada visita:

$$V_{\text{every}}(S_0) = \frac{1}{10} \sum_{i=0}^9 G_i = \frac{10 + 9 + 8 + 7 + 6 + 5 + 4 + 3 + 2 + 1}{10} = \frac{55}{10} = 5,5$$

1.1.2. Parte 2

Para calcular el valor teórico del estado no-terminal con $p = 0,9$, usamos la ecuación de Bellman:

$$V(S_0) = \mathbb{E}[R + \gamma V(S')]$$

donde:

- Con probabilidad $1 - p = 0,1$: transición al terminal, $R = 1$, $V(S_T) = 0$
- Con probabilidad $p = 0,9$: transición a sí mismo, $R = 1$, $V(S_0)$

La ecuación queda:

$$\begin{aligned} V(S_0) &= (1 - p) \cdot (1 + \gamma \cdot 0) + p \cdot (1 + \gamma \cdot V(S_0)) \\ &= (1 - p) \cdot 1 + p \cdot (1 + 1 \cdot V(S_0)) \\ &= (1 - p) + p + pV(S_0) \end{aligned}$$

Resolviendo para $V(S_0)$:

$$V(S_0) = 1 + pV(S_0)$$

$$V(S_0) - pV(S_0) = 1$$

$$(1 - p)V(S_0) = 1$$

$$V(S_0) = \frac{1}{1 - p}$$

Para $p = 0,9$:

$$V_{\text{teórico}}(S_0) = \frac{1}{1 - 0,9} = \frac{1}{0,1} = 10$$

En este episodio particular, la estimación de *primera-visita* coincide exactamente con el valor verdadero (10). Esto tiene sentido: con $\gamma = 1$ y recompensa +1 en cada transición, el retorno desde la primera visita es simplemente el número total de pasos del episodio, que fue 10. La estimación de *cada-visita* es menor (5.5) porque promedia retornos decrecientes a lo largo del episodio.

2. Ejercicio 2

Demostrar que la política $\epsilon - Greedy$, definida de la siguiente manera

$$\pi(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{si } a = a^* \\ \frac{\epsilon}{|A(s)|} & \text{si } a \neq a^* \end{cases}$$

es una distribución de probabilidad válida, donde $|A(s)|$ es el número de acciones posibles para el estado s , $\epsilon < 1$ es un número positivo pequeño, y a^* es la acción óptima (decisión greedy) para el estado s . ¿Hay que pedir alguna condición sobre ϵ ?

2.1. Resolución

Para que $\pi(a|s)$ sea una distribución de probabilidad válida, debe cumplir dos condiciones:

1. Normalización: La suma de las probabilidades de todas las acciones posibles debe ser igual a 1, es decir, $\sum_{a \in A(s)} \pi(a|s) = 1$.
2. No negatividad: $\pi(a|s) \geq 0$ para todas las acciones a en el conjunto de acciones $A(s)$.

2.1.1. No negatividad

Para $A \neq a^*$ $\pi(a|s) = \frac{\epsilon}{|A(s)|} \geq 0$. Esto se puede demostrar que es mayor o igual a 0 si $\epsilon \geq 0$.

Si $A = a^*$ $\pi(a|s) = 1 - \epsilon + \frac{\epsilon}{|A(s)|} \geq 0$

Se puede reescribir como $1 - \epsilon(1 - \frac{1}{|A(s)|})$

$1 - \epsilon(1 - \frac{1}{|A(s)|}) \geq 0$, entonces la expresión va a ser mayor o igual a 0 si $1 \geq \epsilon(1 - \frac{1}{|A(s)|})$.

De aquí surge una condición necesaria para ϵ : $\epsilon \leq \frac{1}{|A(s)|-1}$.

2.1.2. Normalización

$$\sum_a \pi(a|s) = \pi(a^*|s) + \sum_{a \neq a^*} \pi(a|s)$$

Remplazando los valores de $\pi(a|s)$:

$$= 1 - \epsilon + \frac{\epsilon}{|A(s)|} + \sum_{a \neq a^*} \frac{\epsilon}{|A(s)|}$$

Remplazamos por el número de acciones menos 1 (la acción óptima):

$$\begin{aligned} &= 1 - \epsilon + \frac{\epsilon}{|A(s)|} + (|A(s)| - 1) \frac{\epsilon}{|A(s)|} \\ &= 1 - \epsilon + \frac{\epsilon}{|A(s)|} + \epsilon - \frac{\epsilon}{|A(s)|} \\ &= 1 - \epsilon + \epsilon = 1 \end{aligned}$$

Por lo tanto, se cumple la condición de normalización.

3. Ejercicio 3

Se dice que una política π es $\epsilon - soft$ si $\pi(a|s) \geq \frac{\epsilon}{|A(s)|} \forall a \neq a^* \forall s$. Demostrar que la política $\epsilon - Greedy \pi'(a|s) \geq \frac{\epsilon}{|A(s)|}$ (definida en el ejercicio 1) es igual o mejor que cualquier política $\epsilon - soft$, es decir, $v_{\pi'}(s) \geq v_{\pi}(s) \forall s$.

3.1. Resolución

Con la información recibida, tenemos que demostrar (por el teorema de la mejora de la política) que:

$$q_{\pi}(s, \pi'(s)) \geq v_{\pi}(s)$$

Sabemos que:

$$q_\pi(s, \pi'(s)) = E[G_t | S_t = s, A_t = \pi'(s)]$$

como $A_t = \pi'(s)$ es determinístico, lo podemos reescribir:

$$q_\pi(s, \pi'(s)) = E_\pi[G_t | S_t = s] = \sum_g gp(g|s)$$

hacemos la probabilidad marginal:

$$= \sum_g \sum_a p(g, a|s)$$

aplicamos el teorema de Bayes:

$$= \sum_g \sum_a p(g|s, a)p(a|s)$$

sabiendo que $p(a|s) = \pi'(a|s)$ y $\sum_g p(g|s, a) = q(s, a)$:

$$q_\pi(s, \pi'(s)) = \sum_a \pi'(a|s)q(s, a)$$

esta sumatoria se puede separar en la acción óptima y las demás:

$$= \pi'(a^*|s)q(s, a^*) + \sum_{a \neq a^*} \pi'(a|s)q(s, a)$$

reemplazamos los valores de $\pi'(a|s)$:

$$\begin{aligned} &= (1 - \epsilon + \frac{\epsilon}{|A(s)|})q_\pi(s, a^*) + \sum_{a \neq a^*} \frac{\epsilon}{|A(s)|} q_\pi(s, a) \\ &= (1 - \epsilon)q_\pi(s, a^*) + \frac{\epsilon}{|A(s)|} \sum_a q_\pi(s, a) \end{aligned}$$

distribuyendo $q_\pi(s, a^*)$:

$$q_\pi(s, a^*)(1 - \epsilon) + q_\pi(s, a^*)\frac{\epsilon}{|A(s)|} + \frac{\epsilon}{|A(s)|} \sum_{a \neq a^*} q_\pi(s, a)$$

junto las sumatorias $\forall a$:

$$= q_\pi(s, a^*)(1 - \epsilon) + \frac{\epsilon}{|A(s)|} \sum_a q_\pi(s, a)$$

reemplazo $q_\pi(s, a)$ por:

$$= q_\pi(s, a^*) = \sum_a c(a)q_\pi(s, a) \text{ si } \sum_a c(a) = 1$$

Asumimos que $q \sum_a c(a)q_\pi(s, a) \leq q_\pi(s, a^*)$

$$q_\pi(s, a^*) \geq \frac{\epsilon}{|A(s)|} \sum_{|A(s)|} q_\pi(s, a) + (1 - \epsilon) \sum_a c(a) q_\pi(s, a)$$

Elijo unos coeficientes definidos como:

$$c(a) = \frac{\pi(a|s) - \frac{\epsilon}{|A(s)|}}{1 - \epsilon}$$

sabiendo que la sumatoria de todos los coeficientes es 1:

$$\sum_a c(a) = \sum_a \frac{\pi(a|s) - \frac{\epsilon}{|A(s)|}}{1 - \epsilon} = \frac{1 - \epsilon}{1 - \epsilon} = 1$$

remplazando $c(a)$ en la desigualdad:

$$q_\pi(s, a^*) \geq \frac{\epsilon}{|A(s)|} \sum_{|A(s)|} q_\pi(s, a) + \sum_a \pi(a|s) q_\pi(s, a) - \frac{\epsilon}{|A(s)|} \sum_a q_\pi(s, a)$$

cancelo los términos semejantes:

$$q_\pi(s, a^*) \geq \sum_a \pi(a|s) q_\pi(s, a) \stackrel{\text{definición}}{=} v_\pi(s)$$

entonces,

$$q_\pi(s, \pi'(s)) \geq v_\pi(s)$$

que es equivalente (por teorema de la mejora de la política) a:

$$\nu_{\pi'}(s) \geq \nu_\pi(s)$$

4. Ejercicio 4

Dada una trayectoria de acciones y estados $A_t, S_{t+1}, A_{t+1}, \dots, S_T$ en un proceso de decisión markoviano (MDP) con política $\pi(a|s)$, demostrar que la probabilidad conjunta de esa trayectoria se puede escribir como:

$$P[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} \pi(A_k|S_k) p(S_{k+1}|S_k, A_k)$$

Nota: considere $P[S_t] = 1$.

4.1. Resolución

Por la regla de la cadena:

$$\begin{aligned} P[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] &= P[S_t] \cdot P[A_t|S_t] \\ &\quad \cdot P[S_{t+1}|S_t, A_t] \\ &\quad \cdot P[A_{t+1}|S_t, A_t, S_{t+1}] \\ &\quad \cdot P[S_{t+2}|S_t, A_t, S_{t+1}, A_{t+1}] \\ &\quad \dots \end{aligned}$$

En un MDP el siguiente estado depende solo del estado y acción actuales:

$$P[S_{k+1}|S_t, A_t, \dots, S_k, A_k] = P(S_{k+1}|S_k, A_k)$$

Y por política estocástica, la acción depende solo del estado actual:

$$P[A_k|S_t, A_t, \dots, S_k] = \pi(A_k|S_k)$$

Aplicando estas propiedades:

$$P[S_t, A_t, S_{t+1}, \dots, S_T] = P[S_t] \prod_{k=t}^{T-1} \pi(A_k|S_k) \cdot P(S_{k+1}|S_k, A_k)$$

Dado que $P[S_t] = 1$, obtenemos:

$$P[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} \pi(A_k|S_k) P(S_{k+1}|S_k, A_k)$$

5. Ejercicio 5

Usando el resultado del ejercicio 4, demostrar que el importance-sampling ratio correspondiente a la aplicación del método off-policy es:

$$\rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|S_k)}$$

5.1. Resolución

Sabiendo que:

$$P_\pi[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} \pi(A_k|S_k) P(S_{k+1}|S_k, A_k)$$

De manera análoga, la probabilidad de la misma trayectoria bajo la política de comportamiento b es:

$$P_b[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T] = \prod_{k=t}^{T-1} b(A_k|S_k)P(S_{k+1}|S_k, A_k)$$

El *importance-sampling ratio* se define como el cociente entre la probabilidad de la trayectoria bajo la política objetivo y la probabilidad bajo la política de comportamiento:

$$\begin{aligned} \rho_{t:T-1} &= \frac{P_\pi[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T]}{P_b[S_t, A_t, S_{t+1}, A_{t+1}, \dots, S_T]} \\ &= \frac{\prod_{k=t}^{T-1} \pi(A_k|S_k)P(S_{k+1}|S_k, A_k)}{\prod_{k=t}^{T-1} b(A_k|S_k)P(S_{k+1}|S_k, A_k)} \\ &= \frac{\prod_{k=t}^{T-1} \pi(A_k|S_k) \cdot \prod_{k=t}^{T-1} P(S_{k+1}|S_k, A_k)}{\prod_{k=t}^{T-1} b(A_k|S_k) \cdot \prod_{k=t}^{T-1} P(S_{k+1}|S_k, A_k)} \end{aligned}$$

simplificamos la fracción:

$$= \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|S_k)}$$

6. Ejercicio 6

Demostrar que la fórmula de la implementación incremental de un promedio ponderado, es decir, el promedio ponderado

$$V_n = \frac{\sum_{k=1}^{n-1} W_k G_k}{\sum_{k=1}^{n-1} W_k}$$

puede calcularse incrementalmente con la fórmula:

$$V_{n+1} = V_n + \frac{W_n}{C_n} [G_n - V_n]$$

con $C_{n+1} = C_n + W_{n+1}$.

6.1. Resolución

Sea $C_n = \sum_{k=1}^n W_k$ el acumulador de pesos hasta el paso n . Entonces:

$$V_n = \frac{\sum_{k=1}^n W_k G_k}{C_n}$$

Por definición:

$$V_{n+1} = \frac{\sum_{k=1}^{n+1} W_k G_k}{C_{n+1}} = \frac{\sum_{k=1}^{n+1} W_k G_k}{C_n + W_{n+1}}$$

Podemos escribir:

$$V_{n+1} = \frac{\sum_{k=1}^n W_k G_k + W_{n+1} G_{n+1}}{C_n + W_{n+1}}$$

Sabemos que $\sum_{k=1}^n W_k G_k = V_n \cdot C_n$, entonces:

$$V_{n+1} = \frac{V_n C_n + W_{n+1} G_{n+1}}{C_n + W_{n+1}}$$

Como $C_{n+1} = C_n + W_{n+1}$:

$$\begin{aligned} V_{n+1} &= \frac{V_n C_n + W_{n+1} G_{n+1}}{C_{n+1}} \\ &= \frac{V_n C_n}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \end{aligned}$$

Podemos reescribir el primer término:

$$\begin{aligned} V_{n+1} &= \frac{V_n C_n}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ &= \frac{V_n (C_{n+1} - W_{n+1})}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ &= \frac{V_n C_{n+1} - V_n W_{n+1}}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ &= V_n - \frac{V_n W_{n+1}}{C_{n+1}} + \frac{W_{n+1} G_{n+1}}{C_{n+1}} \\ V_{n+1} &= V_n + \frac{W_{n+1} G_{n+1} - V_n W_{n+1}}{C_{n+1}} \\ &= V_n + \frac{W_{n+1}}{C_{n+1}} (G_{n+1} - V_n) \end{aligned}$$

Si reemplazamos $n + 1$ por n en la fórmula final (es decir, consideramos la actualización del paso $n - 1$ al paso n), obtenemos:

$$V_{n+1} = V_n + \frac{W_n}{C_n}[G_n - V_n]$$