

Aprendizaje Reforzado: Trabajo final

José Saint Germain

4 de diciembre de 2025

1. Introducción

El objetivo de este trabajo es realizar generar un análisis y discusión sobre el artículo *A reinforcement learning approach to explore the role of social expectations in altruistic behavior* (Castañón et al., 2023). En el mismo se realizará un resumen del artículo citado, ampliando brevemente sobre los algoritmos en los que se basa, así como en la teoría con la que busca discutir. Adicionalmente, se replicará su trabajo en lenguaje Python para validar sus resultados. Finalmente, se generará una discusión sobre las conclusiones a las que arriba, así como posibles extensiones del trabajo.

2. Resumen del artículo

2.1. Introducción y Motivación

El objetivo general del artículo es lograr modelar el comportamiento altruista de individuos. En particular, busca llevar al campo computacional la teoría de normas sociales propuesta por Cristina Bicchieri (2006). Anteriormente, las teorías económicas y psicológicas tenían un mayor foco en comportamientos puramente egoístas, es decir, comportamientos que buscan maximizar la utilidad individual. Según esta autora, las normas sociales incluyen:

1. expectativas empíricas: las creencias sobre lo que los demás hacen
2. expectativas normativas: las creencias sobre lo que los demás piensan que se debe hacer
3. preferencias condicionales: la disposición a actuar de acuerdo a sus expectativas

Para llevar a cabo este modelado, los autores recurren a un marco de teoría de juegos, los cuales han sido utilizados largamente para capturar comportamiento colaborativo y

comportamiento altruista a partir de la formación de expectativas de los jugadores. El *Juego del Dictador* resulta adecuado para modelar este tipo de comportamiento. Sus reglas básicas son las siguientes:

- Dos jugadores: un **Dictador** y un **Receptor**.
- El Dictador recibe una dotación fija y debe decidir qué fracción donar al Receptor.
- El Receptor no tiene poder de decisión; simplemente recibe lo que el Dictador decide donar.

Engel (2011) mediante un meta-análisis realizó una revisión literaria de juegos del dictador y encontró que, en promedio, los dictadores donan alrededor del 30 % de su dotación. Según Bechler y otros (2015), este comportamiento surge de la influencia que tiene la distancia social entre los miembros de este juego.

Finalmente, para encontrar una manera de actualizar las expectativas de los agentes en un juego de múltiples rondas los autores recurren al aprendizaje por refuerzo, dada la robustez que provee para predecir comportamiento prosocial en grandes poblaciones. Este artículo replicará en buena medida el trabajo realizado por Pereda y otros (2017) en el cual presenta un modelo basado en agentes gobernados por las expectativas generadas por el Juego del Dictador, en las cuales los agentes reaccionan a estímulos empíricos basados en la dinámica de aprendizaje reforzado de Bush-Mosteller (1951). La diferencia radica en resolver las siguientes limitaciones encontradas al artículo de Pereda y otros:

- La ausencia de expectativas normativas.
- La falta de variabilidad y de dinámicas en la caracterización de los agentes (la susceptibilidad a estímulos, lo cual puede ser interpretado como la tasa de aprendizajes).
- El mismo peso asignado a interacciones positivas y negativas.

El artículo, entonces, buscará mejorar el modelo para lograr representar los siguientes comportamientos humanos observados en el Juego del Dictador: (i) donaciones promedio del 30 %, (ii) la alta heterogeneidad en el perfil de los donantes y (iii) la existencia de un número no trivial de humanos con un comportamiento no colaborativo.

2.2. Juego del Dictador

Dadas las condiciones iniciales y las diferencias establecidas con el trabajo de Pereda y otros, el Juego del Dictador modelado consta de los siguientes pasos:

2.2.1. Asignación de aspiraciones

Todos los agentes (aun no están divididos en dictadores y receptores) comienzan con los siguientes atributos iniciales:

1. Aspiración inicial ($a_{i,t} = 0$): ubicada aleatoriamente en el rango $[0, \phi]$, donde ϕ es la dotación inicial fija que reciben los dictadores en cada ronda del juego. Este atributo refleja la cantidad de dinero que esperan obtener en la primera ronda del juego.

2. Susceptibilidad (l_i): representa la sensibilidad del agente a los estímulos sociales. Se asigna aleatoriamente en el rango $[0, 1]$. Teóricamente los autores distinguen entre susceptibilidad normativa y empírica, pero en esta versión del modelo se utiliza una única susceptibilidad.

2.2.2. Asignación de roles

Los agentes son catalogados durante esta ronda como dictador (j) o receptor (k) de manera aleatoria. La cantidad de dictadores y recipientes deben ser la misma para que puedan ser apareados.

2.2.3. Interacción normativa entre dictadores

Cada dictador comunica honestamente el porcentaje de la dotación $\theta_{j,t}$ que planea donar al receptor a una cantidad Q de otros dictadores. El parámetro $\theta_{j,t}$ no solo toma en cuenta las aspiraciones originales del dictador sino también un parámetro ruido $\delta_{j,t}^{nor}$ que toma en cuenta el efecto de una 'mano temblorosa' a la hora de la comunicación. La donación comunicada tiene la siguiente forma:

$$\theta_{j,t} = \max(0, \min(\phi, a_{j,t} * (1 + \delta_{j,t}^{nor}))) \quad (1)$$

La interacción normativa se conforma por la diferencia entre las aspiraciones del dictador y la donación comunicada a otros dictadores, normalizado por la dotación inicial para obtener un valor entre 0 y 1.

$$I_{j,t}^{nor} = \frac{\theta_{j,t} - a_{j,t}}{\phi} \quad (2)$$

Con Q cantidad de interacciones, la totalidad de la interacción normativa recibida por el dictador j en la ronda t es:

$$s_{j,t}^{nor} = \frac{\sum_{m=1}^Q I_{m,t}^{nor}}{Q} = \frac{\sum_{j'} \theta_{j',t} - a_{j,t} \sum_{j'} 1}{\phi * Q} = \frac{\sum_{j'} \phi_{j',t}}{\phi * Q} - \frac{a_{j,t}}{\phi} \quad (3)$$

De esta forma, se puede destacar varias cuestiones. Primero, que solo el dictador que busca consejo actualiza sus aspiraciones en base a la interacción normativa. Segundo, que el dictador consultado no actualiza las suyas. Tercer, que la interacción $s_{j,t}^{nor}$ puede tomar valores entre -1 y 1, siendo positivo cuando la donación comunicada es mayor a la aspiración del dictador, y negativo en el caso contrario.

2.2.4. Los dictadores actualizan sus aspiraciones

Tanto la susceptibilidad como las aspiraciones de los dictadores se actualizan en base a la interacción normativa recibida. Primero, la susceptibilidad se actualiza de la siguiente forma:

$$l_{j,t}^{nor} = \begin{cases} l_{j,t-1}^{nor} * (1 + W^{nor,pos} * s_{j,t}^{nor}) & \text{si } s_{j,t}^{nor} \geq 0 \\ l_{j,t-1}^{nor} * (1 + W^{nor,neg} * s_{j,t}^{nor}) & \text{si } s_{j,t}^{nor} < 0 \end{cases} \quad (4)$$

siendo $W^{nor,pos}$ y $W^{nor,neg}$ hiperparámetros (entre 0 y 1) representando los pesos asignados a las interacciones normativas positivas y negativas respectivamente.

luego, las aspiraciones se actualizan de la siguiente forma:

$$a_{j,t} = \begin{cases} a_{j,t-1} + (\phi - a_{j,t-1}) * l_{j,1}^{nor} & \text{si } s_{j,t}^{nor} \geq 0 \\ a_{j,t-1} + a_{j,t-1} * l_{j,1}^{nor} & \text{si } s_{j,t}^{nor} < 0 \end{cases} \quad (5)$$

De estas fórmulas podemos interpretar que el estímulo positivo incrementa la susceptibilidad del agente y, secuencialmente, sus aspiraciones. Por el contrario, un estímulo negativo reduce la susceptibilidad y las aspiraciones del agente. Ampliando la interpretación, las interacciones positivas implican que la aspiración promedio de otros dictadores es mayor a la del agente, llevando al dictadora a aumentar sus aspiraciones personales. Lo contrario ocurre en el caso de interacciones negativas.

2.2.5. Los dictadores proceden a donar

Cada dictador dona a su respectivo receptor una cantidad $\delta_{j,t}$ con la siguiente fórmula, incorporando una variable ruido $\delta_{j,t}^{emp}$, que representa la 'mano temblorosa' al momento de donar:

$$\delta_{j,t} = \max(0, \min(\phi, (\phi - a_{j,t}) * (1 + \delta_{j,t}^{emp}))) \quad (6)$$

Esta donación $\delta_{j,t}$ se convierte en la donación $\pi_{k,t}$ recibida por el receptor k en la ronda t .

2.2.6. Interacción empírica entre receptores

Como resultado de la donación recibida, cada receptor reacciona al estímulo empírico generado por la misma:

$$s_{k,t}^{emp} = \frac{\pi_{k,t} - a_{k,t}}{\phi} \quad (7)$$

lo cual se traduce a que, si la donación recibida es mayor a la aspiración del receptor, el estímulo empírico será positivo, y negativo en el caso contrario.

2.2.7. Los receptores actualizan sus aspiraciones

Similar a los dictadores, los receptores actualizan su susceptibilidad y sus aspiraciones en base al estímulo empírico recibido:

$$l_{k,t}^{emp} = \begin{cases} l_{k,t-1}^{emp} * (1 + W^{emp,pos} * s_{k,t}^{emp}) & \text{si } s_{k,t}^{emp} \geq 0 \\ l_{k,t-1}^{emp} * (1 + W^{emp,neg} * s_{k,t}^{emp}) & \text{si } s_{k,t}^{emp} < 0 \end{cases} \quad (8)$$

$$a_{k,t} = \begin{cases} a_{k,t-1} + (\phi - a_{k,t-1}) * l_{k,1}^{emp} & \text{si } s_{k,t}^{emp} \geq 0 \\ a_{k,t-1} + a_{k,t-1} * l_{k,1}^{emp} & \text{si } s_{k,t}^{emp} < 0 \end{cases} \quad (9)$$

2.2.8. Repetir hasta finalizar iteraciones

Se repiten los pasos anteriores por una cantidad T de rondas, donde en cada ronda se reasignan los roles de dictador y receptor de manera aleatoria, así como se actualizan las aspiraciones y susceptibilidades de los agentes.

2.3. Supuestos de la implementación computacional

Adicional a las fórmulas y dinámicas presentadas en el artículo, los autores realizan ciertos supuestos para la implementación computacional del modelo:

- Asumen cierta predisposición al egoísmo, por lo que la aspiración $a_{i,t=0}$ inicial de cada agente se toma de una distribución uniforme en el rango $[0, 5\phi; \phi]$.
- La susceptibilidad se toma de una distribución uniforme en el rango $[0; 0,5]$.
- Se asume que los agentes cuentan con una sola susceptibilidad (y no una empírica y otra normativa). Esto se justifica en que los autores esperan un comportamiento consistente a ser igualmente reactivos a estímulos empíricos y normativos.

- Se asume que las interacciones normativas son más frecuentes que las empíricas, por lo que se asume $Q = 5$.
- Respecto a las 'manos temblorosas', se asume que los humanos son más susceptibles a comportarse consistentemente con sus creencias en ambientes empíricos que en los normativos, por lo que $\delta_{j,t}^{norm} \sim N(0; 0,05)$ y $\delta_{j,t}^{nor} \sim N(0; 0,1)$.

2.4. Resultados Principales

Como comentarios finales de configuración, se realizaron 10 juegos de 100 rondas con 1000 agentes. Estos juegos se ejecutaron con semillas diferentes para luego promediarse. Si no se logra un régimen estable antes de las 100 rondas, se extiende 10 rondas más hasta lograrlo, aunque siempre se logra antes de las 100 rondas.

Para evaluar los resultados, se visualizará la distribución de las últimas donaciones realizadas por los agentes, así como la distribución de las susceptibilidades finales de los mismos. Adicionalmente, se mostrarán estos resultados para diferentes valores de los pesos asignados a las interacciones positivas y negativas, tanto normativas como empíricas ($W_{pos}^{emp}, W_{neg}^{emp}, W_{pos}^{norm}, W_{neg}^{norm}$).

Primero se evalúan los resultados fijando $W_{pos}^{emp} = W_{neg}^{emp} = 0$ y variando los pesos asignados a las interacciones normativas. De los resultados de esta configuración visualizados en la figura 1 se deriva que la variación en las interacciones normativas positivas no parecen generar una diferencia en la donación promedio, mientras que las negativas si logran correr el promedio donado hacia la izquierda. En la figura análoga 2, fijando $W_{pos}^{norm} = W_{neg}^{norm} = 0$ y variando los pesos asignados a las interacciones empíricas, también se observa una mayor influencia de los pesos asignados a las interacciones negativas, visualizado también con fuerza en la evolución de las susceptibilidades. Los autores asignan mayor influencia a las interacciones empíricas a que tienen una mayor frecuencia que las normativas, dando mayor lugar a casos extremos, si bien modificar el Q no modifica sensiblemente estas distribuciones.




Figura 1: Distribución de donaciones y susceptibilidades finales con $W_{pos}^{emp} = W_{neg}^{emp} = 0$





Figura 2: Distribución de donaciones y susceptibilidades finales con $W_{pos}^{nor} = W_{neg}^{nor} = 0$

Moviéndonos a analizar escenarios donde se fijan los pesos normativos o empíricos en 1 (figura 4 y 3), y se varían los pesos del otro tipo de interacción, se observa la misma tendencia: las interacciones empíricas son más relevantes para definir las donaciones finales.





Figura 3: Distribución de donaciones y susceptibilidades finales con $W_{pos}^{emp} = W_{neg}^{emp} = 1$




Figura 4: Distribución de donaciones y susceptibilidades finales con $W_{pos}^{nor} = W_{neg}^{nor} = 1$

Finalmente, los autores destacan que niveles altos y positivos normativos ayudan a conservar altos niveles de susceptibilidad en las rondas finales. Por otro lado, los perfiles de donaciones que reflejan mejor los resultados experimentales (figura 3 o cuarta columna de la figura 4), presentan niveles prácticamente nulos de susceptibilidad, sugiriendo que los agentes no son más susceptibles a cambios en sus conductas altruistas.

2.5. Discusión y conclusiones

De los resultados obtenidos, los autores extraen tres conclusiones preliminares, poniendo foco en entornos 'socialmente consistentes', es decir con susceptibilidad final nula

- La donación promedio está cerca del 30 por ciento de la dotación inicial.
- La distribución es heterogénea. Si bien hay algunas donaciones por arriba del 50 por ciento, la decisión modal está cerca de la donación equitativa.
- Hay un número no trivial de agentes (10 por ciento) que decide quedarse con toda la dotación, incluso mayor a los que deciden donar más de la mitad.

Adicionalmente, destacan las siguientes características coincidentes con la bibliografía:

1. Las expectativas empíricas tienden a dominar las normativas: la creencia sobre lo que hacen otros actores son más fuertes que las creencias sobre lo que otros piensan que se debe hacer.
2. Las interacciones negativas tienen mayor peso que las positivas.
3. En los casos donde el estímulo converge a cero, se puede inferir que no se requieren normas sociales que las mantengan: los agentes pueden mantener comportamientos prosociales sin necesidad de estímulos que redirijan su comportamiento.

4. En consecuencia, el rol inicial de la susceptibilidad se vuelve muy relevante.

Habiendo llegado a estas conclusiones, los autores ponen foco en una configuración específica de pesos: dejando los pesos negativos en 1. Recorriendo todos los pesos positivos encuentran que la configuración que más se acerca al treinta por ciento relevado por Engel (2011) es el que le asigna $1/3$ a los pesos positivos (valor remarcado en la figura 5). Resulta interesante que esta relación entre pesos (negativos tres veces mayores que positivos) se refleja en la literatura psicológica sobre el tema, en donde las dinámicas negativas tienen entre tres y cinco veces más peso que las positivas (Fredrickson, 2013; Coleman et al., 2021).




Figura 5: Distribución de donaciones y susceptibilidades finales con $W_{neg}^{emp} = W_{neg}^{nor} = 1$

Como un último aspecto relevante de esta configuración de hiperparámetros, la evolución de la susceptibilidad promedio (algorítmicamente, la tasa de aprendizaje) muestra una forma exponencial decreciente (figura 6). Este coincide con lo observado por Westhoff y otros (2020) en su estudio de la adaptación de los agentes en ambientes cooperativos y no cooperativos a partir del ajuste de expectativas empíricas a partir de mecanismos de aprendizaje por refuerzo. Además, toma valores similares de tasa de aprendizaje (en el rango entre 0 y 0.25) que decae a su valor estacionario en alrededor de 20 rondas.




Figura 6: Evolución de la susceptibilidad promedio con $W_{neg}^{emp} = W_{neg}^{nor} = 1$ y $W_{pos}^{emp} = W_{pos}^{nor} = 0,33$

Finalmente, los autores proponen líneas de investigación futuras enfocadas en: (1) complejizar los perfiles psicológicos de los agentes incorporando creencias normativas personales; (2) profundizar en cómo las interacciones generan cambios de fase en la susceptibilidad poblacional; (3) explorar topologías de red distintas a la 'totalmente conectada' para estudiar efectos de homofilia y redes de referencia; y (4) aplicar el modelo al diseño de políticas públicas prosociales (ej. subsidios) bajo escenarios de riesgo.

3. Marco teórico del artículo

Para profundizar y comprender mejor el funcionamiento de este algoritmo, ampliaremos sobre el algoritmo de Bush-Mosteller (1951) utilizado en el artículo, describiendo no solo su funcionamiento, sino la manera en que se inserta y dialoga con la bibliografía inicial sobre aprendizaje por refuerzo.

En su recorrido por la historia del aprendizaje por refuerzo, Sutton y Barto (1998) describen los trabajos que investigaron el desarrollo de autómatas aprendices, diseñados para resolver problemas de aprendizaje no asociativos (es decir, que no implica aprender a actuar en más de una situación) y puramente seleccionistas como el de k-armed bandits. Entre estos trabajos se destaca el de autómatas aprendices estocásticos, los cuales actualizan la probabilidad de sus acciones en base a señales de recompensa. Esta línea de investigación es la que derivaría en el desarrollo de una teoría estadística del aprendizaje (Bush y Mosteller, 1955)

La teoría estadística del aprendizaje desarrollada por Bush y Mosteller (1955) sirvió como basamento para investigaciones futuras en modelos económicos clásicos, teniendo como objetivo estudiar agentes artificiales que actuaran más como personas reales que como agentes económicos ideales. En este sentido, este enfoque de investigación se expandió hacia la aplicación de aprendizaje reforzado en la teoría de juegos.

Es dentro de este marco que Bush y Mosteller desarrollaron su algoritmo (1951), el cual busca describir la estructura básica de situaciones de aprendizaje sencillas. El objetivo principal del algoritmo es describir el cambio en la probabilidad (p) de que ocurra la respuesta que se está estudiando, después de la ejecución de dicha respuesta. El algoritmo cuenta con la siguiente arquitectura:

$$Qp = p + a(1 - p) - bp \quad (10)$$

donde:

- Q : operador matemático. Cuando se aplica a una probabilidad p , se obtiene un nuevo valor de probabilidad.
- $a(1-p)$: término de refuerzo positivo. Si la respuesta es seguida por un refuerzo positivo, la probabilidad de que la respuesta se repita aumenta en proporción a $(1-p)$, siendo a un parámetro entre 0 y 1 que representa la tasa de aprendizaje.
- $-bp$: término de refuerzo negativo. Si la respuesta es seguida por un refuerzo negativo, la probabilidad de que la respuesta se repita disminuye en proporción a p , siendo b un parámetro entre 0 y 1 que representa la tasa de aprendizaje.

Esta arquitectura se asemeja a la utilizada en el capítulo 2 de Sutton y Barto (1998), donde se describe el método de *implementación incremental* para estimar el valor esperado de una acción en un problema de k-armed bandit.

$$\text{Nueva Estimación} \leftarrow \text{Vieja Estimación} + \text{Tamaño del Paso} \cdot [\text{Objetivo} - \text{Vieja Estimación}] \quad (11)$$

Adaptando la ecuación 11, la nueva estimación es Qp , la vieja estimación es p , el tamaño del paso es a o b dependiendo si el refuerzo es positivo o negativo y el error corresponde al término que decrementa p ($-bp$).

Retomando el artículo de Castañón y otros, podemos observar que es la actualización en la aspiración de los agentes (ecuaciones 5 y 9) la que sigue la lógica del algoritmo de Bush-Mosteller. De esa manera, la probabilidad nueva Qp es representada por la nueva aspiración $a_{i,t}$, la probabilidad vieja p por la aspiración previa $a_{i,t-1}$ y el tamaño del paso a o b por la susceptibilidad $l_{i,1}^{nor}$ o $l_{i,1}^{emp}$. De esa manera, con las funciones partidas dependiendo de los estímulos normativos y empíricos, la ecuación contempla tanto el término de refuerzo positivo como el negativo.

4. Replicación del artículo

La totalidad del experimento realizado por los autores fue replicado utilizando el lenguaje Python 3.12.0, utilizando las librerías numpy para cálculos numéricos y numba para optimización de código. La totalidad de los gráficos de esta monografía fueron generados de los datos obtenidos de la replicación del experimento, los cuales coinciden con los presentados por los autores. El código para generar los resultados pueden encontrarse en el siguiente repositorio de GitHub. Adicional a la visualización estática de los resultados, se generaron visualizaciones interactivas en (Observable) para evaluar la variación en las distribuciones de donaciones y susceptibilidades al variar los pesos asignados a las interacciones así como la modificación en la evolución promedio de la susceptibilidad de los agentes.

Referencias

- Bush, R. R., & Mosteller, F. (1951). A mathematical model for simple learning. *Psychological review*, 58(5), 313.
- Bush, R. R., & Mosteller, F. (1955). Stochastic Models for. *Learning*.
- Sutton, R. S., Barto, A. G., et al. (1998). *Reinforcement learning: An introduction* (Vol. 1). MIT press Cambridge.
- Bicchieri, C. (2006, noviembre). *The Grammar of Society* (None, Vol. None). Cambridge University Press. <https://doi.org/https://doi.org/10.1017/CBO9780511616037>
- Engel, C. (2011). Dictator games: A meta study. *Experimental economics*, 14(4), 583-610.
- Fredrickson, B. L. (2013). Updated thinking on positivity ratios.
- Bechler, C., Green, L., & Myerson, J. (2015). Proportion offered in the Dictator and Ultimatum Games decreases with amount and social distance. *Behavioural Processes*, 115, 149-155. <https://doi.org/https://doi.org/10.1016/j.beproc.2015.04.003>
- Pereda, M., Brañas-Garza, P., Rodríguez-Lara, I., & Sánchez, A. (2017). The emergence of altruism as a social norm. *Scientific reports*, 7(1), 9684.
- Westhoff, B., Molleman, L., Viding, E., van den Bos, W., & van Duijvenvoorde, A. C. (2020). Developmental asymmetries in learning to adjust to cooperative and uncooperative environments. *Scientific reports*, 10(1), 21761.
- Coleman, P. T., Fisher, J., Fry, D. P., Liebovitch, L. S., Chen-Carrel, A., & Souillac, G. (2021). How to live in peace? Mapping the science of sustaining peace: A progress report. *American Psychologist*, 76(7), 1113.
- Castañón, R., Campos, F. A., & Villar, J. (2023). A reinforcement learning approach to explore the role of social expectations in altruistic behavior. *Scientific Reports*, 13(1), 1717. <https://doi.org/10.1038/s41598-023-28659-0>